1 Opis algorytmu

Zaimplementowana została strategia ewolucyjna $(\mu + \lambda)$ w swojej pierwszej najprostszej wersji. Algorytm szuka minimum funkcji q. W każdym pokoleniu z μ rodziców powstaje λ dzieci, gdzie dziecko jest zmutowaną kopią jednego, losowo wybranego rodzica.

$$x' = x + \sigma\,\mathcal{N}(0, I)$$

W tej wersji algorytmu, σ jest stałe przez cały przebieg oraz nie ma krzyżowania. Porównując tę strategię z algorytmem gradientu prostego, σ jest tutaj swego rodzaju odpowiednikiem parametru α. Z puli rodziców i dzieci zostaje μ osobników o najmniejszej wartości q, więc rodzic może przejść dalej do następnej populacji (różnica względem strategii (μ, λ)). Po mutacji każda współrzędna przycinana jest do dziedziny. Zaimplementowane zostały dwa warunki stopu. Pierwszy z nich (`fe_max`) to osiągnięcie maksymalnej liczby wywołań funkcji celu równej:

$$FE_{\max} = 100 \cdot n$$

Drugi to `target`, czyli osiągnięcie przez najlepszego osobnika wartości konkretnego progu.

2 Plan eksperymentów

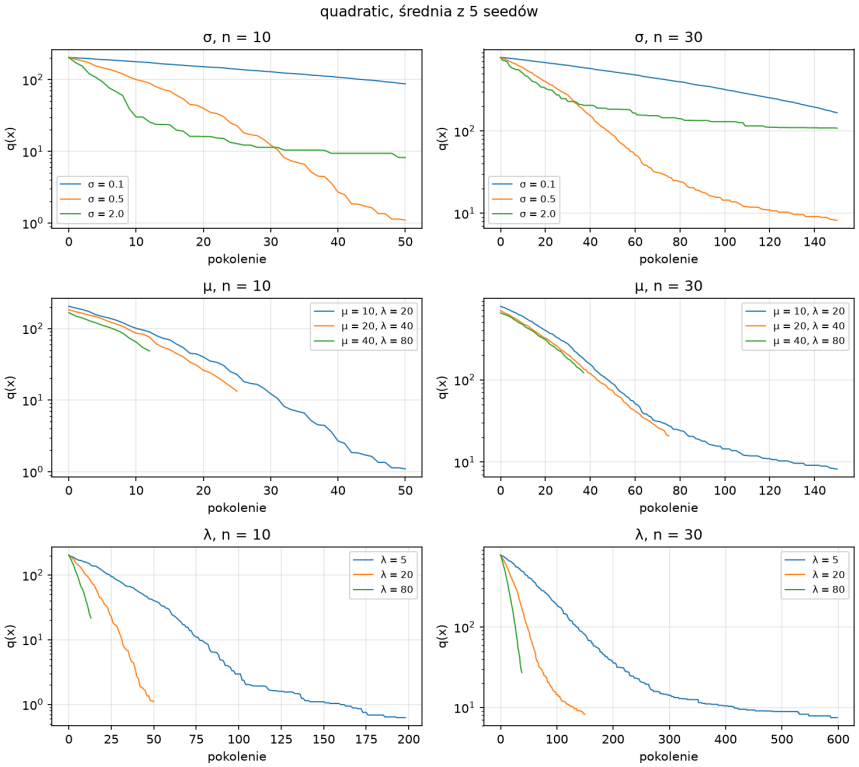
Zbadane zostały trzy funkcje dla wymiarowości $n = 10$ i $n = 30$. Funkcja kwadratowa $q(x) = \sum_{i=1}^{n} x_i^2$ jest ta sama co w zadaniu z gradientem prostym. Została zbadana na dziedzinie $[-10, 10]^n$ i ma minimum w zerze. Funkcje F3 i F18 pochodzą z CEC 2017, zbadane zostały na dziedzinie $[-100, 100]^n$. Wartości optimów w tym benchmarku wynoszą $F_i = 100 \cdot i$, stąd 300 dla F3 i 1800 dla F18. Próg `target` ustawiony został na 10^{-4} dla funkcji kwadratowej oraz na wyżej wymienione optima dla F3 i F18. Badany solver jest algorytmem stochastycznym, dlatego też każde ustawienie uruchomione zostało pięć razy, seedami 0-4. W tabeli wyników jest średnia oraz odchylenie standardowe, natomiast wykresy posiadają krzywe średnich wartości.

Tabela 1: Badane ustawienia. W każdym wierszu zmieniana jest jedna wielkość.

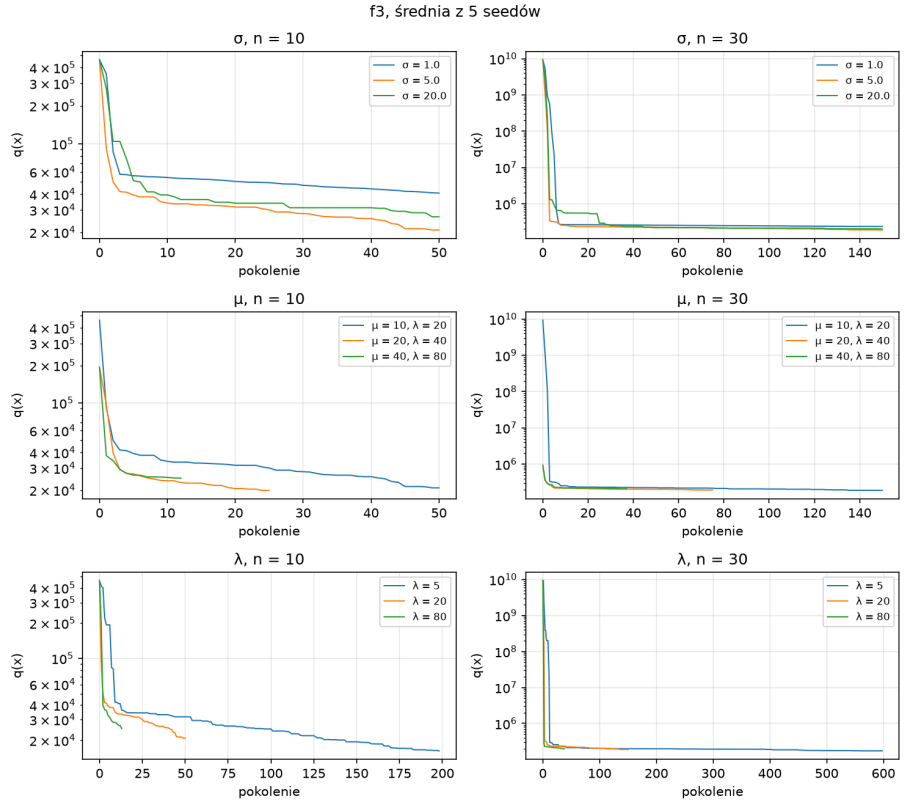
Co się zmienia	Kwadratowa	F3 i F18
σ, przy $\mu = 10$ i $\lambda = 20$	0,1; 0,5; 2	1; 5; 20
pary (μ, λ)	$(10, 20)$, $(20, 40)$, $(40, 80)$ przy $\sigma = 0{,}5$	te same pary przy $\sigma = 5$
λ, przy $\mu = 10$	5; 20; 80 przy $\sigma = 0{,}5$	te same wartości przy $\sigma = 5$

Trzy wartości σ dostosowano do dziedziny konkretnych funkcji. Na $[-100, 100]^n$ każda jest dziesięć razy większa niż na $[-10, 10]^n$. Pokolenie 0 to populacja początkowa, a każde kolejne to jedna iteracja: urodzenie się dzieci, ich ocena, selekcja. Na wykresach oś pozioma to pokolenie, a oś pionowa jest logarytmiczna. Krótsza krzywa przy większym λ oznacza, że ten sam budżet ocen zmieścił się w mniejszej liczbie pokoleń. Algorytm uruchamiany był w WSL na systemie Windows.

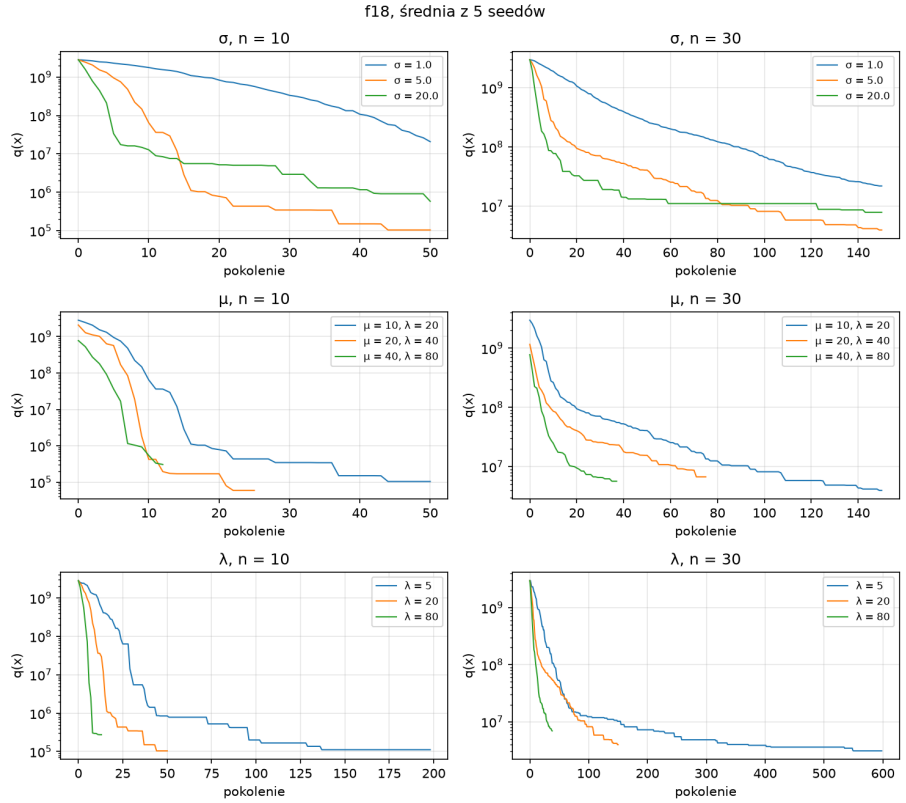
3 Uzyskane wyniki



Wykres 1: Funkcja kwadratowa, średnia z pięciu seedów. Wiersze: σ, μ, λ. Kolumny: $n = 10$ i $n = 30$.



Wykres 2: Funkcja F3, średnia z pięciu seedów. Wiersze: σ, μ, λ. Kolumny: $n = 10$ i $n = 30$.



Wykres 3: Funkcja F18, średnia z pięciu seedów. Wiersze: σ, μ, λ. Kolumny: $n = 10$ i $n = 30$.

3.1 Funkcja kwadratowa

Tabela 2: Funkcja kwadratowa. Średnia i odchylenie końcowego q, $\mu = 10$, $\lambda = 20$.

n	$\sigma = 0{,}1$	$\sigma = 0{,}5$	$\sigma = 2$
10	$87{,}6 \pm 25{,}1$	$1{,}10 \pm 0{,}39$	$8{,}22 \pm 2{,}76$
30	167 ± 38	$8{,}25 \pm 1{,}25$	108 ± 24

Środkowe $\sigma = 0{,}5$ jest najlepsze przy obu wymiarowościach n. Przy $\sigma = 0{,}1$ krok jest za krótki, żeby w ustalonym budżecie zejść do minimum. Krok $\sigma = 2$ natomiast za bardzo rozprasza dzieci. Większa liczba μ i λ pogarsza wyniki, ponieważ `fe_max` zostaje osiągnięte w mniejszej liczbie pokoleń. Najlepszy wynik to $0{,}623 \pm 0{,}191$, przy $n = 10$, $\mu = 10$, $\lambda = 5$ i $\sigma = 0{,}5$. Na tej samej funkcji gradient prosty przy $\alpha = 0{,}1$, doszedł do $2{,}0 \cdot 10^{-17}$ w 99 iteracjach. Gradient liczy nachylenie i robi krok w stronę malejącej wartości funkcji. Implementowana strategia nie zna kierunku spadku. Do rodzica dodaje losowy szum o wielkości σ, a zostają punkty, które po ocenie funkcji wypadły lepiej.

3.2 Funkcja F3

Tabela 3: F3. Średnia i odchylenie końcowej wartości, $\mu = 10$, $\lambda = 20$.

n	$\sigma = 1$	$\sigma = 5$	$\sigma = 20$
10	$4{,}07 \cdot 10^4 \pm 1{,}67 \cdot 10^4$	$2{,}08 \cdot 10^4 \pm 1{,}05 \cdot 10^4$	$2{,}65 \cdot 10^4 \pm 3{,}74 \cdot 10^3$
30	$2{,}34 \cdot 10^5 \pm 5{,}57 \cdot 10^4$	$1{,}88 \cdot 10^5 \pm 3{,}94 \cdot 10^4$	$1{,}99 \cdot 10^5 \pm 5{,}45 \cdot 10^4$

$\sigma = 5$ daje najlepsze wyniki, ale różnice są często mniejsze niż odchylenia standardowe. Na wykresie widać szybki spadek po którym następuje wypłaszczenie. Osiągane wyniki są daleko nad wartością minimalną funkcji. Przy $n = 10$ najniższą średnią ($1{,}62 \cdot 10^4 \pm 1{,}19 \cdot 10^4$) daje $\lambda = 5$. Przy $n = 30$ wyniki są o jeden rząd wielkości wyższe.

3.3 Funkcja F18

Tabela 4: F18. Średnia i odchylenie końcowej wartości, $\mu = 10$, $\lambda = 20$.

n	$\sigma = 1$	$\sigma = 5$	$\sigma = 20$
10	$2{,}08 \cdot 10^7 \pm 4{,}46 \cdot 10^7$	$1{,}04 \cdot 10^5 \pm 1{,}29 \cdot 10^5$	$5{,}82 \cdot 10^5 \pm 3{,}26 \cdot 10^5$
30	$2{,}19 \cdot 10^7 \pm 2{,}94 \cdot 10^7$	$3{,}96 \cdot 10^6 \pm 2{,}26 \cdot 10^6$	$7{,}88 \cdot 10^6 \pm 4{,}38 \cdot 10^6$

Dla $\sigma = 1$ odchylenie standardowe przy $n = 10$ jest ponad dwa razy większe od średniej, więc o wyniku decyduje pojedyncze uruchomienie. Spośród badanych σ najniższe średnie daje $\sigma = 5$, ale nadal są one daleko od optimum równego 1800. Różnice są rzędu 10^5 przy $n = 10$ i rzędu milionów przy $n = 30$. Przy $\lambda = 80$ średnia jest wyższa niż przy $\lambda = 5$ i $\lambda = 20$. Najniższą średnią ogólnie ($5{,}93 \cdot 10^4 \pm 1{,}94 \cdot 10^4$) uzyskano dla $n = 10$, $\mu = 20$, $\lambda = 40$ i $\sigma = 5$.

4 Wnioski

1. Tak jak w przypadku algorytmu gradientu prostego i parametru α, siła mutacji σ ma dwie strony. Zbyt mała wartość wyczerpuje `fe_max` przed dojściem do minimum, a zbyt duża za bardzo rozprasza dzieci.

2. Budżet liczy wywołania funkcji celu, a każde dziecko wymaga jednego wywołania. Większa wartość parametrów λ i μ wyczerpuje `fe_max` już w kilkunastu pokoleniach. Dla funkcji kwadratowej przy $n = 10$, $\mu = 10$ i $\sigma = 0{,}5$ średnie końcowe q wynosi 0,623 dla $\lambda = 5$ oraz 21,7 dla $\lambda = 80$.

3. Dla funkcji kwadratowej która jest prostą doliną z jednym minimum, algorytm gradientu prostego jest zdecydowanie lepszy. Przy $n = 10$ i $\alpha = 0{,}1$ schodzi do $2{,}0 \cdot 10^{-17}$ w 99 iteracjach. Najlepsza strategia ewolucyjna przy tej samej funkcji kończy z wartością 0,623 po 1000 ocenach. Gradient idzie w kierunku spadku, natomiast strategia $(\mu + \lambda)$ zna tylko wartość funkcji, więc przy stałym parametrze σ nie jest w stanie dojść do minimum w określonym budżecie.

4. Limit maksymalnej ilości wywołań funkcji celu równy $FE_{\max} = 100 \cdot n$ nie wystarcza żeby zejść do progu żadnej funkcji. F3 staje koło 10^4–10^5 przy progu 300, F18 koło 10^5–10^6 przy progu 1800. Warunek stopu `target` nie zadziałał ani razu.

5. Dla F18 odchylenie standardowe jest często porównywalne z różnicą między średnimi, więc pojedynczy seed może zdominować wynik. Wartość $\sigma = 1$ daje wynik o około dwa rzędy większy niż $\sigma = 5$, ale już w przypadku zmian parametru μ różnica między średnimi jest mniejsza niż odchylenie standardowe z pięciu seedów, więc nie wiadomo które μ jest lepsze.

6. Porównanie jest ograniczone do trzech wartości każdego parametru i pięciu seedów, a parametr σ jest stały przez cały przebieg. Zestawienie z gradientem prostym dotyczy tylko funkcji kwadratowej przy wymiarowości $n = 10$.

Tabela 5: Ustawienia spoza tabel σ, przywoływane we wnioskach.

ustawienie	średnia	odchylenie
kwadratowa, $n = 10$, $\sigma = 0{,}5$		
$\mu = 10$, $\lambda = 5$	0,623	0,191
$\mu = 10$, $\lambda = 80$	21,7	11,4
$\mu = 40$, $\lambda = 80$	48,5	16,1
F18, $n = 10$, $\sigma = 5$		
$\mu = 20$, $\lambda = 40$	$5{,}93 \cdot 10^4$	$1{,}94 \cdot 10^4$
$\mu = 40$, $\lambda = 80$	$3{,}06 \cdot 10^5$	$4{,}53 \cdot 10^5$